

Valutazione di pgvector come database unificato per architetture RAG


Davide Lorenzon

22 Settembre 2026



pat

ZUCCHETTI



Problema

Information retrieval in un contesto
relazionale


**Soluzione
attuale**

Postgres + Elasticsearch per la ricerca

Criticità

- **Overhead** di sincronizzazione e comunicazione
- **Join** lato backend

Pgvector



Dati relazionali + ricerca

Perché adesso

Avanzamento di
pgvector

Da valutare


Fattibilità
tecnica e
performance

Estensione diretta e senza
altri DB esterni

Python




FastAPI




Grafana



full-text search nativa





Interroga **tutte le entità** e
ricostruisce il contesto

Ricerca linked

È il caso d'uso che rende
Elasticsearch inadatto

Semantica

Similarità sui
vettori di
embedding

Full-text

Corrispondenza
lessicale

Ibrida

Fusione delle due
tramite **RRF**

Benefici attesi

- Stack **semplificato**
- **Linking** lato DB
- Integrazione più semplice su DB esistenti
- Proprietà **ACID**

Vincoli

- Solo **full-text nativo** (no dipendenze premature)
- **Pgvector**
- Testo ricercabile diviso in **chunk**
- Più campi ricercabili per entità


Tabella chunk di supporto

Partizionamento su
field_name

Indice **HNSW** su bit vector

Denormalizzazione dei campi
filterable

Oversampling e **rescoring**




Non il focus principale ma
comunque necessaria alla
valutazione

Indice **GIN**

Punteggi sempre **comparabili**

Esplorati workaround



Nessuno scoring BM25:
accettato

Filtering granulare: Overlap tra
array di lessemi

Granularità dello scoring:
Combinazioni di funzioni
semplici

Performance: Accettato

Locust

simula utenti paralleli

Metriche


hit rate, MRR, latenza

Grafana

dashboard collegata a Postgres

Ground truth

da dati sintetici



Volume dati: 10.000 ticket, 50.000 conversation item, 60.000 attachment

Ricerca semantica

200-300ms,
confermata

Fusione ibrida

semplice ed efficace
lato DB

Linking

join performanti su chiave primaria

Volume dati: 10.000 ticket, 50.000 conversation item, 60.000 attachment

Full-text
5-10s

Answer rate 100%
ma su dataset di test

No Block-Max WAND
non replicabile in Postgres



Grazie per l'attenzione!
Domande?