

Valutazione di pgvector come database unificato per architetture RAG


Davide Lorenzon

22 Settembre 2026



pat

ZUCCHETTI



Problema

Information retrieval in un contesto
relazionale


**Soluzione
attuale**

Postgres + Elasticsearch per la ricerca

Criticità

- **Overhead** di sincronizzazione e comunicazione
- **Join** lato backend

Pgvector



Dati relazionali + ricerca

Perché adesso

Avanzamento di
pgvector

Da valutare


Fattibilità
tecnica e
performance

Estensione diretta e senza
altri DB esterni

Python




FastAPI




Grafana



full-text search nativa






Interroga **tutte le entità** e
ricostruisce il contesto

Ricerca linked

È il caso d'uso che rende
Elasticsearch inadatto

Semantica

Similarità sui
vettori di
embedding



Full-text

Corrispondenza
lessicale



Ibrida

Fusione delle due
tramite **RRF**

```
-- Calculate RRF contribution
rfr AS (

  SELECT id,
    1.0 / (60 + rank) AS s FROM fulltext

  UNION ALL

  SELECT id,
    1.0 / (60 + rank) AS s FROM semantic
)

-- Sum the RRF scores, order by them,
-- and join back the original data

SELECT m.id, sum(s), m.description
FROM rfr

JOIN mock_items AS m USING (id)
GROUP BY m.id, m.description
ORDER BY sum(s) DESC
LIMIT 5;
```

Benefici attesi

- Stack **semplificato**
- **Linking** lato DB
- Integrazione più semplice su DB esistenti
- Proprietà **ACID**

Vincoli

- Solo **full-text nativo** (no dipendenze premature)
- **Pgvector**
- Testo ricercabile diviso in **chunk**
- Più campi ricercabili per entità


Tabella chunk di supporto

Partizionamento su
field_name

Indice **HNSW** su bit vector

Denormalizzazione dei campi
filterable

Oversampling e rescoring




Non il focus principale ma
comunque necessaria alla
valutazione

Indice **GIN**

Punteggi sempre **comparabili**

Esplorati workaround



Nessuno scoring BM25:
accettato

Granularità dello scoring:
Combinazioni di funzioni
semplici

Filtering granulare: Overlap tra
array di lessemi

Performance: Accettato

Alternative valutate

pg_text_search

Buone premesse ma troppo
poco maturo

ParedeDB

Licenza non compatibile per
questo progetto

Locust

simula utenti paralleli

Metriche

hit rate, MRR, latenza

Grafana

dashboard collegata a Postgres

Ground truth

da dati sintetici



Volume dati: 10.000 ticket, 50.000 conversation item, 60.000 attachment

Ricerca semantica
200-300ms
confermata

Linking incluso nella
misurazione

Risultati: cosa non ha funzionato

Volume dati: 10.000 ticket, 50.000 conversation item, 60.000 attachment

**Full-text
(e ibrida)**

5-10s una volta
ottimizzata

**No Block-Max
WAND**

non replicabile
senza estensioni



Answer rate 100%
ma su dataset di test

L'accuratezza dipende
da fattori trasversali

Utile principalmente
alla **diagnostica**

Accuratezza in un
contesto reale,
probabilmente più
bassa: **80%** circa

Definizione della **ground truth** non banale



Grazie per l'attenzione!
Domande?